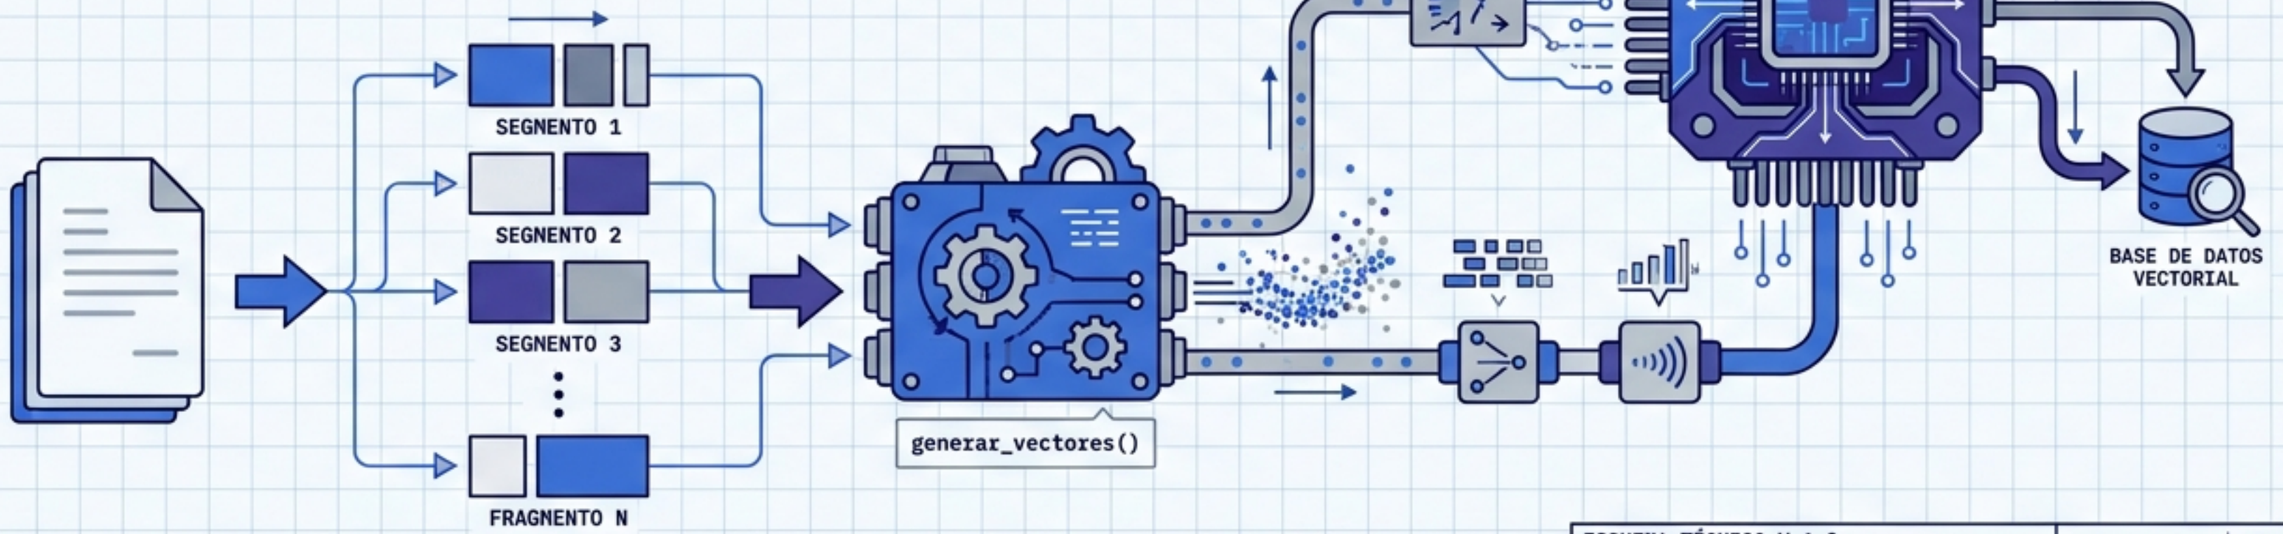
ARQUITECTURA RAG AVANZADA

De los fundamentos a la producción con bases de datos vectoriales y LLMs.



ESQUEMA TÉCNICO V.1.2		INGENIERÍA DE DATOS
FLUJO DE DATOS		
PROYECTO RAG	FECHA: 2824	

Gemini Notebook

Los límites de los modelos de lenguaje congelados



Fecha de corte

No conoce políticas, precios o eventos posteriores a su entrenamiento.



Datos privados

Sin acceso a manuales internos, contratos o bases de datos empresariales.





Alucinaciones

Produce respuestas plausibles pero falsas cuando ignora la respuesta, sin citar fuentes.



Ventana finita

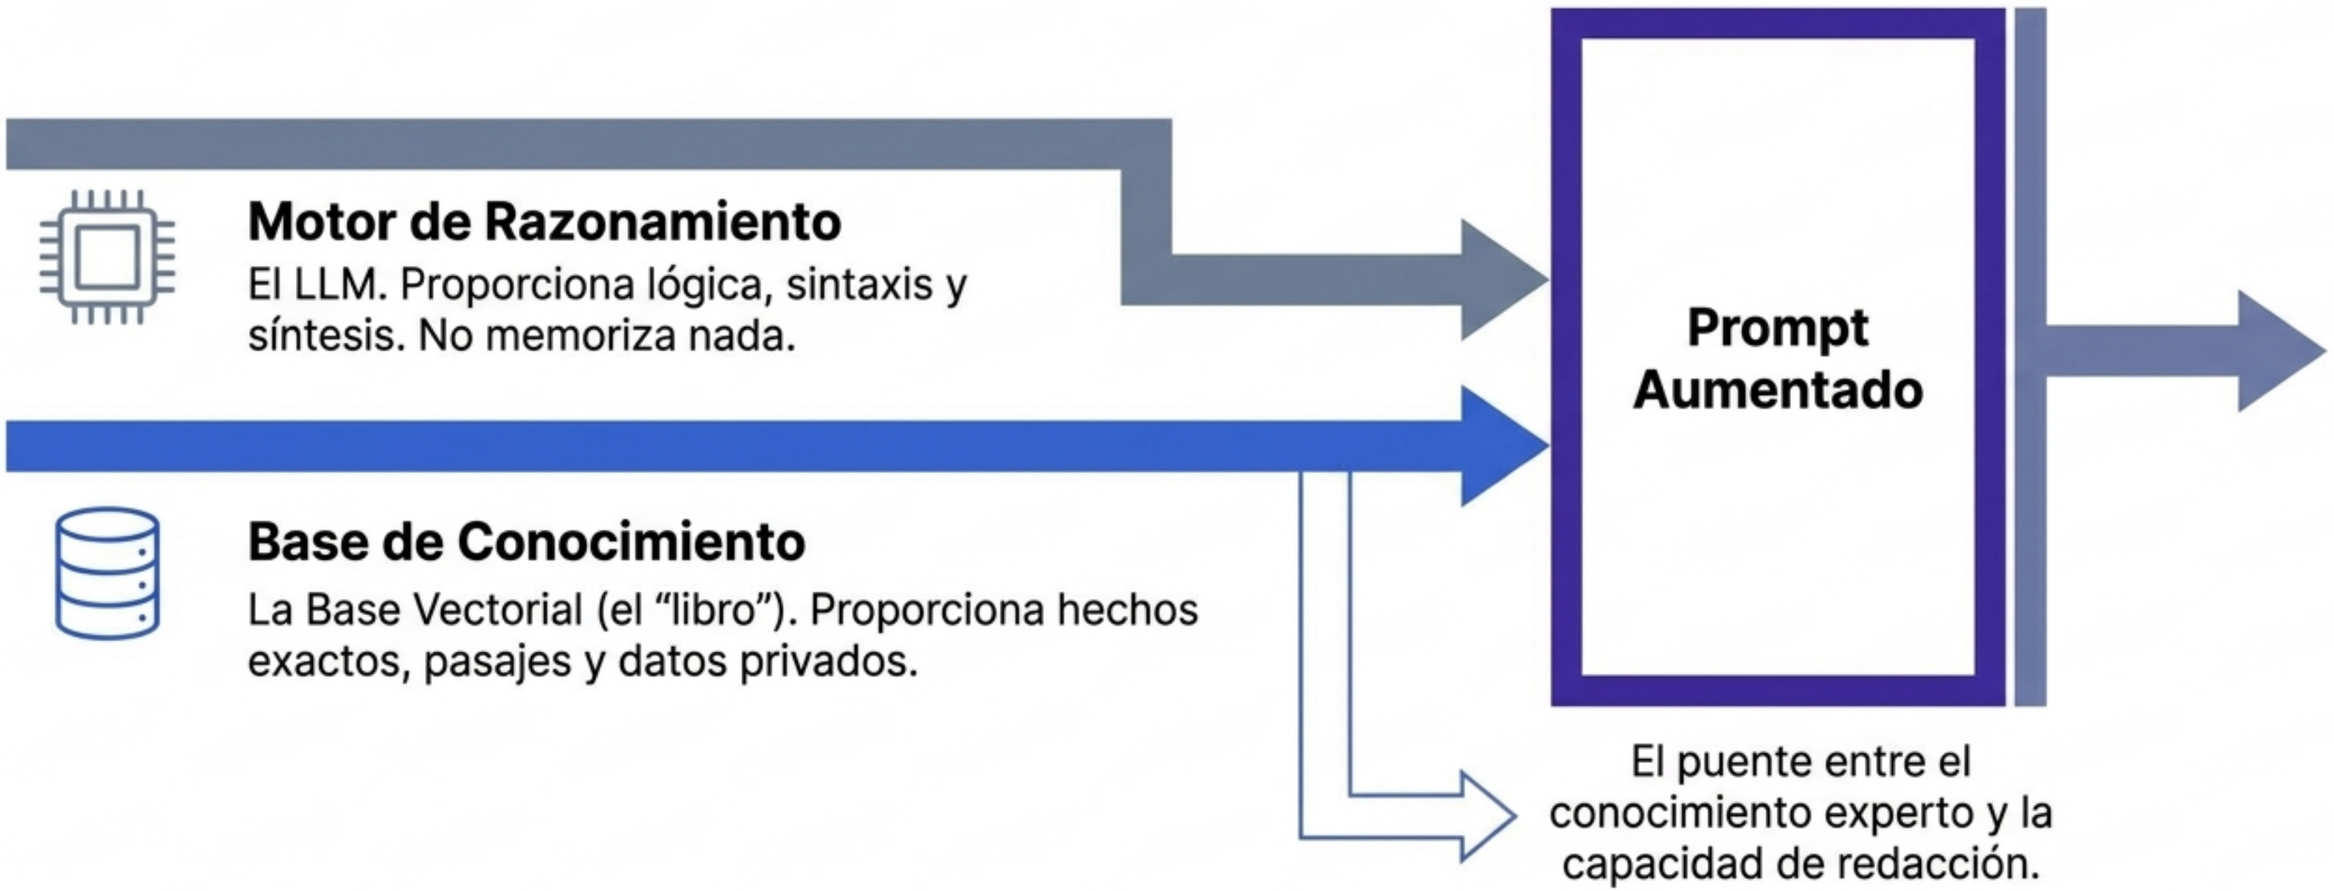
Pegar miles de páginas de contexto en cada consulta no es práctico ni económico.

El fine-tuning enseña CÓMO responder. RAG aporta QUÉ responder.

Gemini Notebook

El paradigma RAG: un examen a libro abierto

Retrieval-Augmented Generation (RAG) separa la **búsqueda de información** de la redacción. El LLM redacta la respuesta usando únicamente la información recuperada de la base de datos propia.



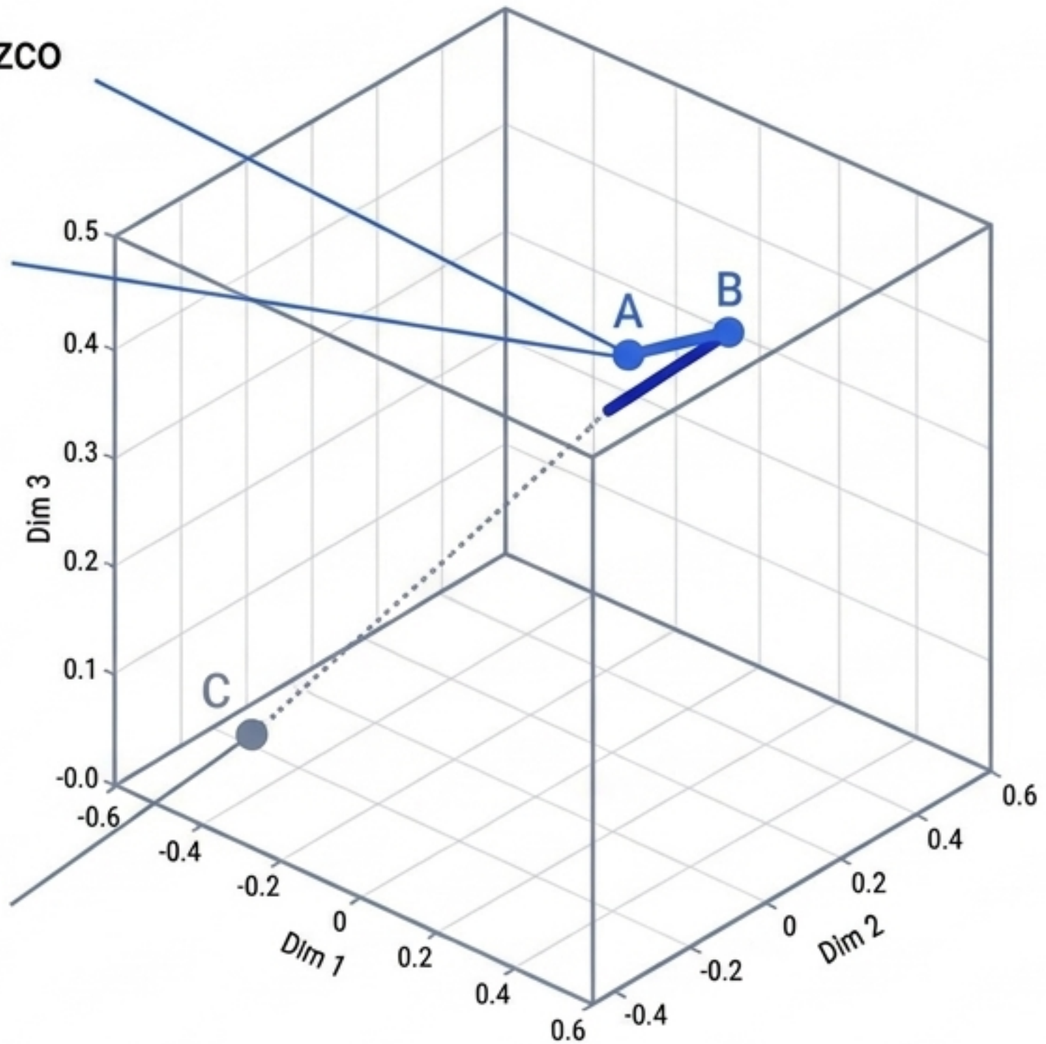
Gemini Notebook

Embeddings: el significado convertido en matemáticas

¿Cómo restablezco mi contraseña?

Olvidé mi clave de acceso

El clima de hoy es soleado



Concepto

Un vector numérico (ej. 384 o 1536 dimensiones) que representa la intención, no las palabras exactas.

Similitud Coseno

Mide el ángulo entre vectores (-1 a 1). “Restablecer contraseña” y “Olvidé mi clave” casi no comparten texto, pero su similitud semántica es ~1.0.

Regla de Oro

El mismo modelo de embeddings debe usarse para indexar documentos y para vectorizar preguntas.

Gemini Notebook

Matriz de decisión para bases de datos vectoriales

Tecnología	Modalidad	Ventaja principal	Cuándo elegir
Chroma	Local / Código abierto	Aprendizaje rápido, sin infraestructura (pip install).	Prototipos y validaciones iniciales.
Pinecone	Nube (Servicio administrado)	Operación sin servidores, alta escalabilidad inmediata.	Producción en la nube sin administrar infraestructura.
Weaviate	Autohospedado / Nube	Búsqueda híbrida nativa y módulos avanzados.	Casos que exigen búsqueda léxica y semántica combinada.
pgvector	Extensión de PostgreSQL	Un solo motor para datos relacionales y vectores.	Sistemas que ya operan fuertemente con PostgreSQL.

Todas permiten asociar `metadatos` (fuente, página, permisos) vitales para filtrar antes de la búsqueda vectorial.

Gemini Notebook

Estrategias de división de texto (Chunking)



Demasiado Pequeño

Se pierde el contexto narrativo; el fragmento por sí solo no se entiende.

Punto Óptimo (200-500 tokens)

Solapamiento (overlap) del 10 al 20% para no cortar ideas.

Demasiado Grande

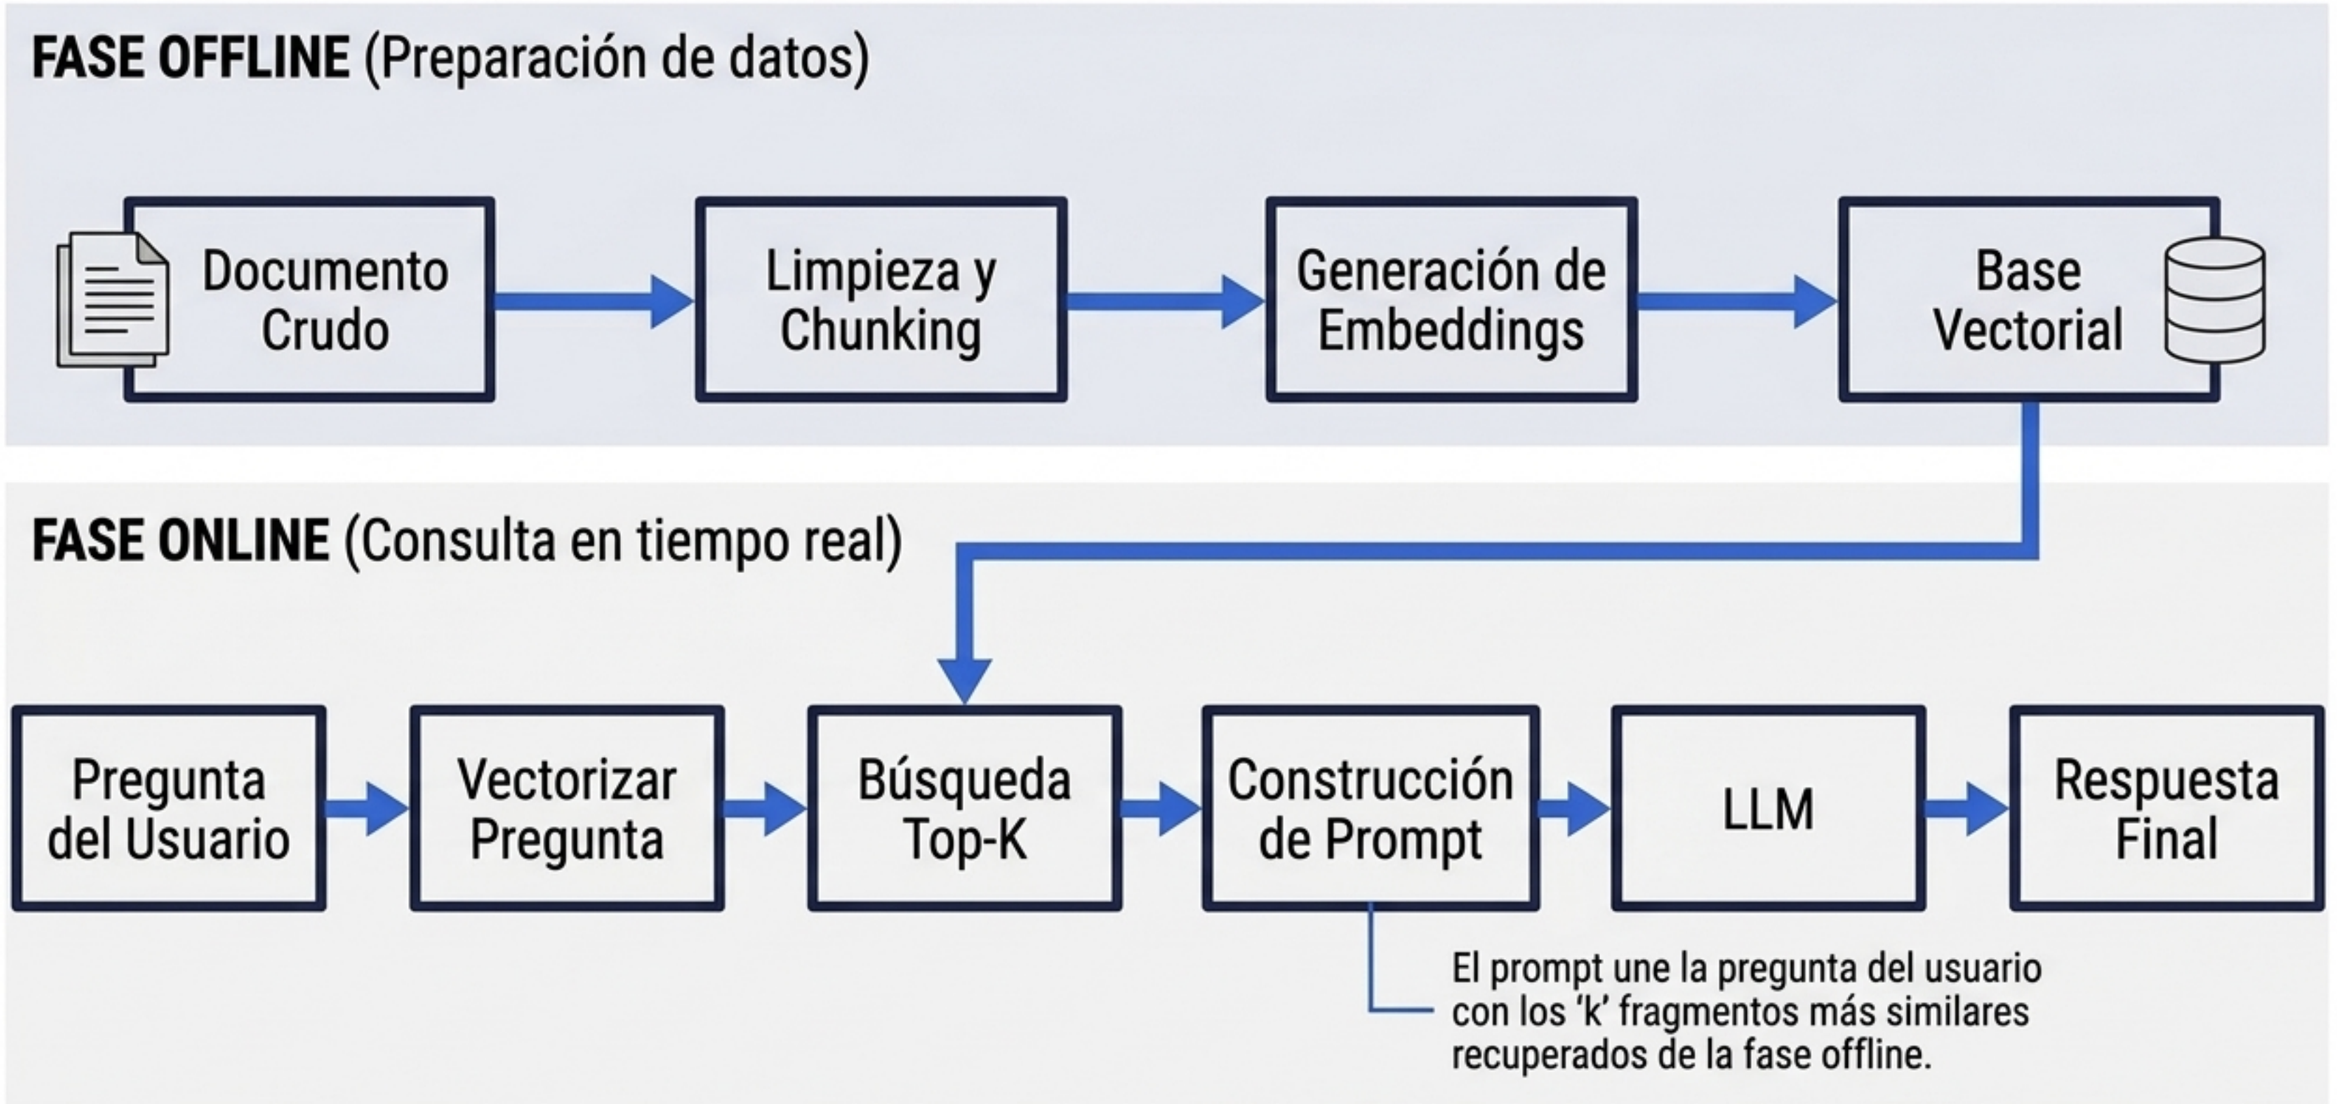
Mezcla múltiples temas, el vector es impreciso y satura el límite del LLM.

Recomendación de Producción: Estrategia Recursiva

Divide progresivamente por párrafos, luego oraciones, hasta alcanzar el límite.
Regla crítica: Limpiar PDFs antes de dividir y enriquecer cada chunk manteniendo sus metadatos (título, página, fuente).

Gemini Notebook

El flujo fundacional: pipeline RAG básico



Gemini Notebook

Los puntos ciegos de la búsqueda puramente vectorial

Búsqueda Semántica (Vectores)

✓ **Fuerza:** Entiende el significado y paráfrasis (ej. ‘costo’ = “precio’).

✗ **Punto Ciego:** Falla con términos exactos, códigos SKUs (‘SKU-4471’), siglas técnicas o artículos de ley específicos.

Búsqueda Léxica (Palabras Clave / BM25)

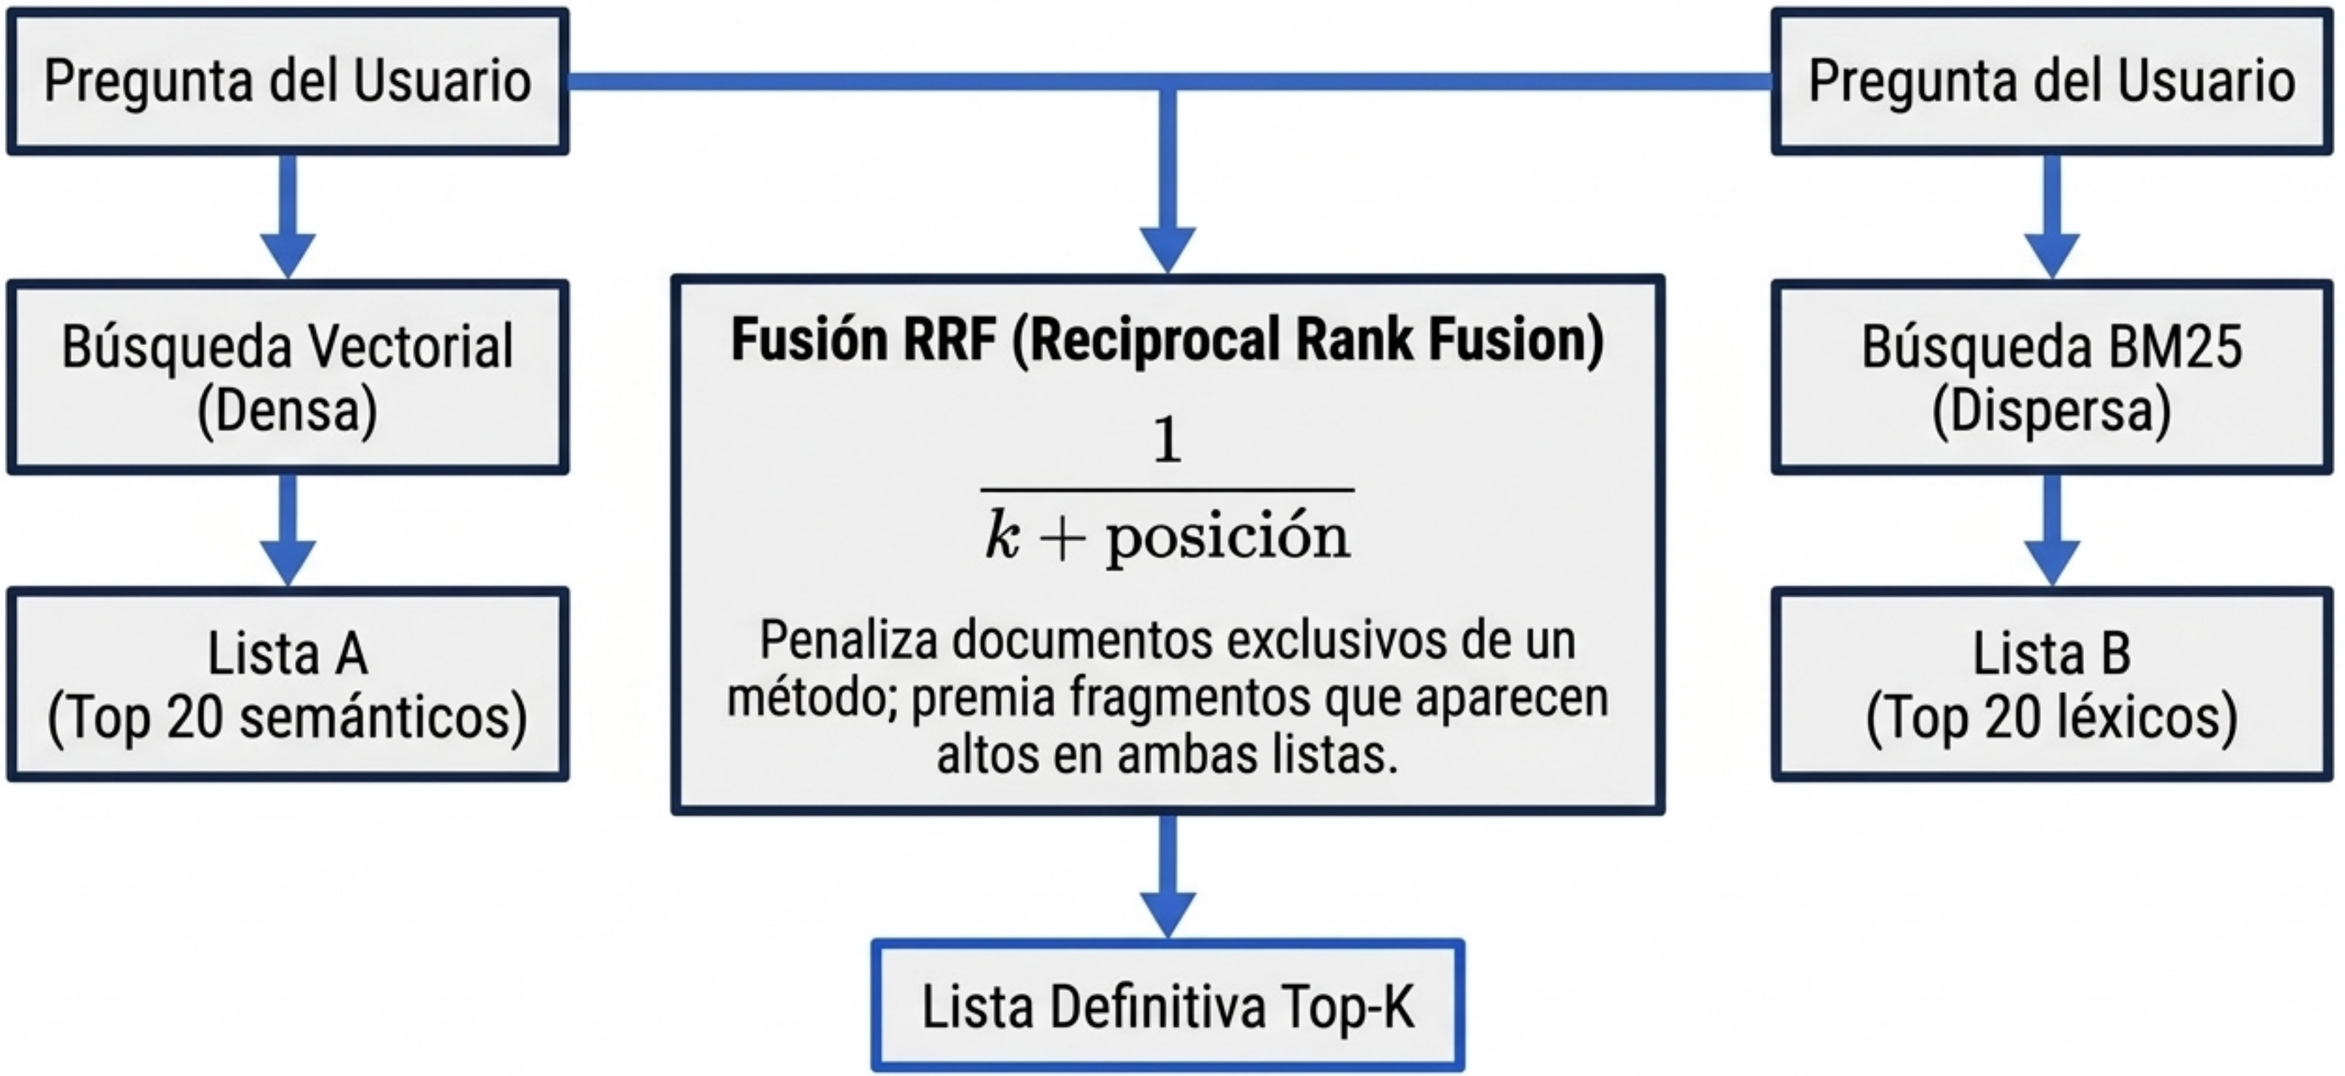
✓ **Fuerza:** Encuentra coincidencias alfanuméricas exactas.

✗ **Punto Ciego:** No entiende el contexto ni sinónimos. Si buscas “ropa de invierno”, ignora documentos que dicen “abrigo polar”.

En entornos empresariales reales, depender de una sola estrategia garantiza fallos en consultas específicas. La solución es combinarlas.

Gemini Notebook

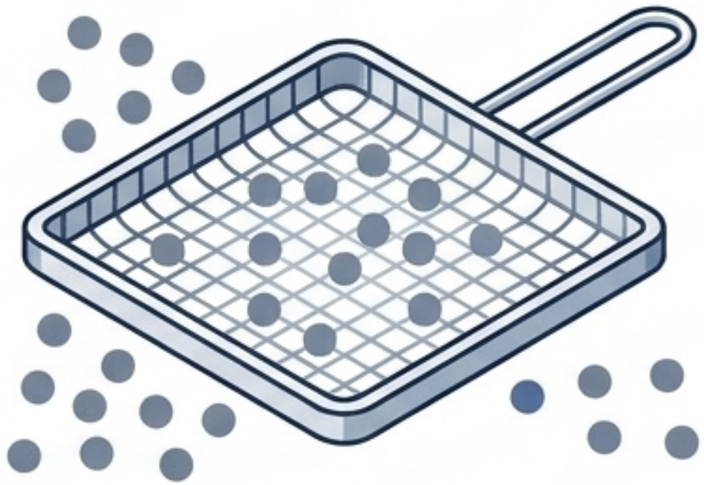
Búsqueda híbrida y Reciprocal Rank Fusion (RRF)



Gemini Notebook

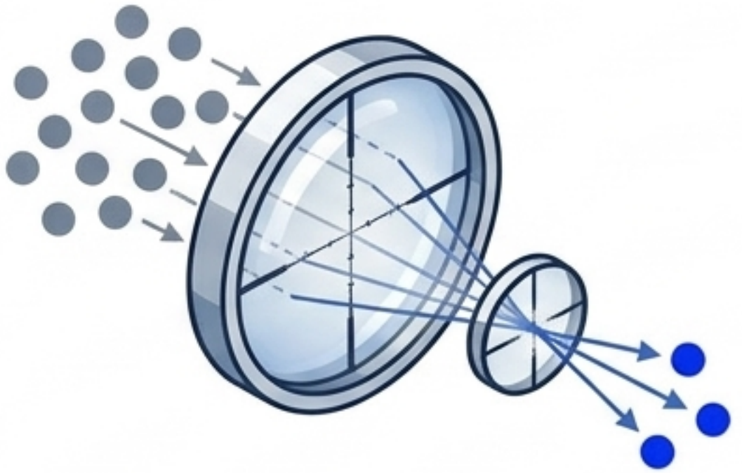
Re-ranking: precisión quirúrgica en dos etapas

Etapa 1: Bi-encoder (La Red Amplia)



Recuperación rápida y aproximada. La pregunta y los fragmentos se vectorizan por separado. Escoge decenas de candidatos en milisegundos.

Etapa 2: Cross-encoder (La Lupa)

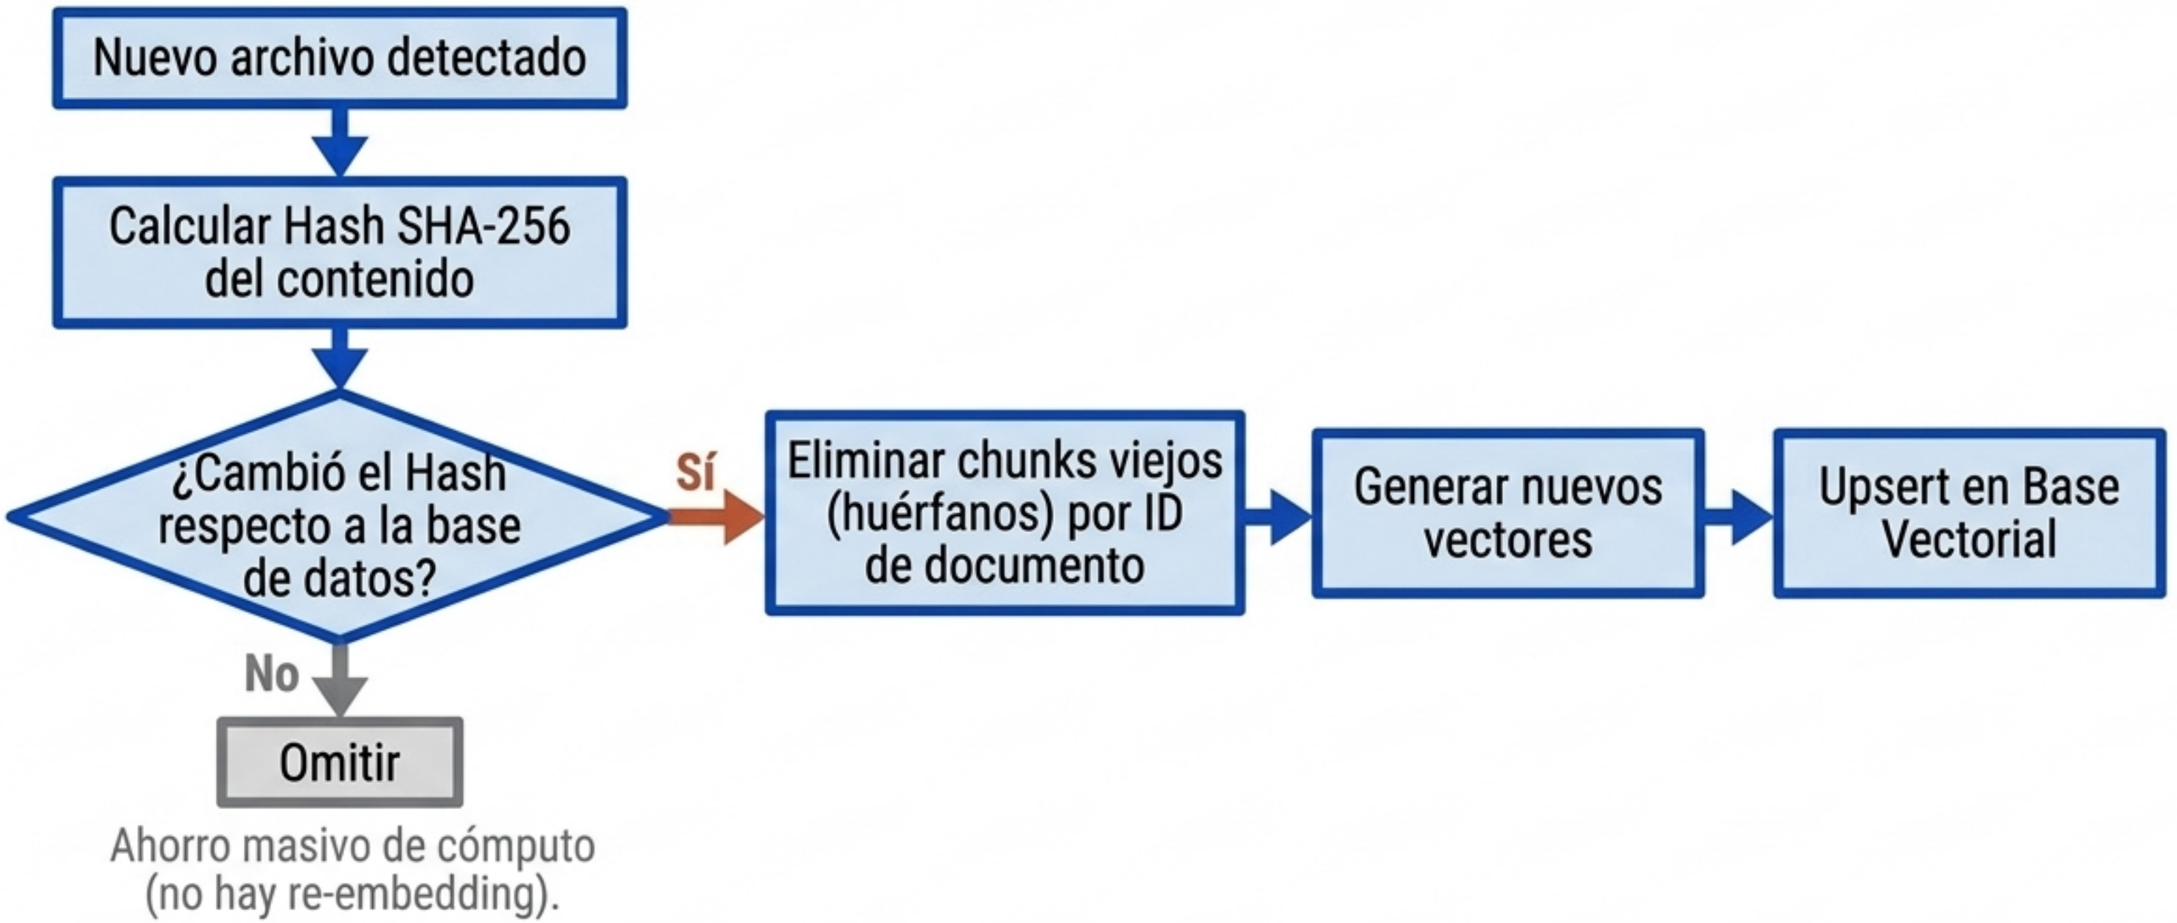


Reordenamiento lento pero ultra-preciso. La pregunta y cada fragmento se procesan juntos. Evalúa la relevancia semántica exacta.

Recuperar amplio (alto recall) y reordenar de forma estricta (alta precisión) garantiza que el LLM reciba solo el contexto más perfecto.

Gemini Notebook

Escalamiento en producción: sincronización incremental



Reconstruir todo el índice en cada cambio es inviable. Construir IDs deterministas (ej. `manual_ti.pdf::0007`) y verificar huellas SHA-256 permite actualizaciones quirúrgicas.

Gemini Notebook

Ingeniería de generación: controlando a Claude

```
Eres un asistente corporativo. Respondes SOLO con la
información de los documentos.
- Si no está, responde: 'No encontré esa información.'
- Cita cada afirmación.

<documentos>
  <documento indice='1'>
    <fuente>manual_rrhh.pdf, p. 7</fuente>
    <contenido>Las vacaciones se solicitan con 15
días...</contenido>
  </documento>
</documentos>

Pregunta: ¿Con cuántos días pido vacaciones?
```

Aislamiento XML: Separar instrucciones de contexto previene “Prompt Injection indirecta” (datos maliciosos en el PDF).

Válvula de Escape: Obligar a admitir que “no sabe” es la medida más eficaz contra las alucinaciones.

Gemini Notebook

Evaluación del sistema (Parte 1): Métricas de Recuperación

Precisión@k

Relevantes recuperados / k

70%

De lo que trajo el sistema, ¿cuánto sirve realmente?

Recall@k (Exhaustividad)

Recuperados / Total relevantes existentes

55%

De todo lo útil que hay en la base, ¿cuánto logramos encontrar?

Hit Rate@k

1 o 0

1 (Sí)

¿Apareció al menos un documento útil en la búsqueda?

MRR (Mean Reciprocal Rank)

1 / Posición del primer acierto

0.67

¿Qué tan arriba en la lista aparece la respuesta correcta?

Si la recuperación falla, ninguna mejora del prompt arreglará el problema (**'basura entra, basura sale'**).

Gemini Notebook

Evaluación del sistema (Parte 2): Calidad de Generación



LLM-as-a-Judge

Fidelidad (Faithfulness)

¿Cada afirmación está respaldada por el contexto recuperado, o el modelo inventó datos?

Relevancia

¿La respuesta aborda directamente lo que el usuario preguntó, sin rodeos?

Corrección

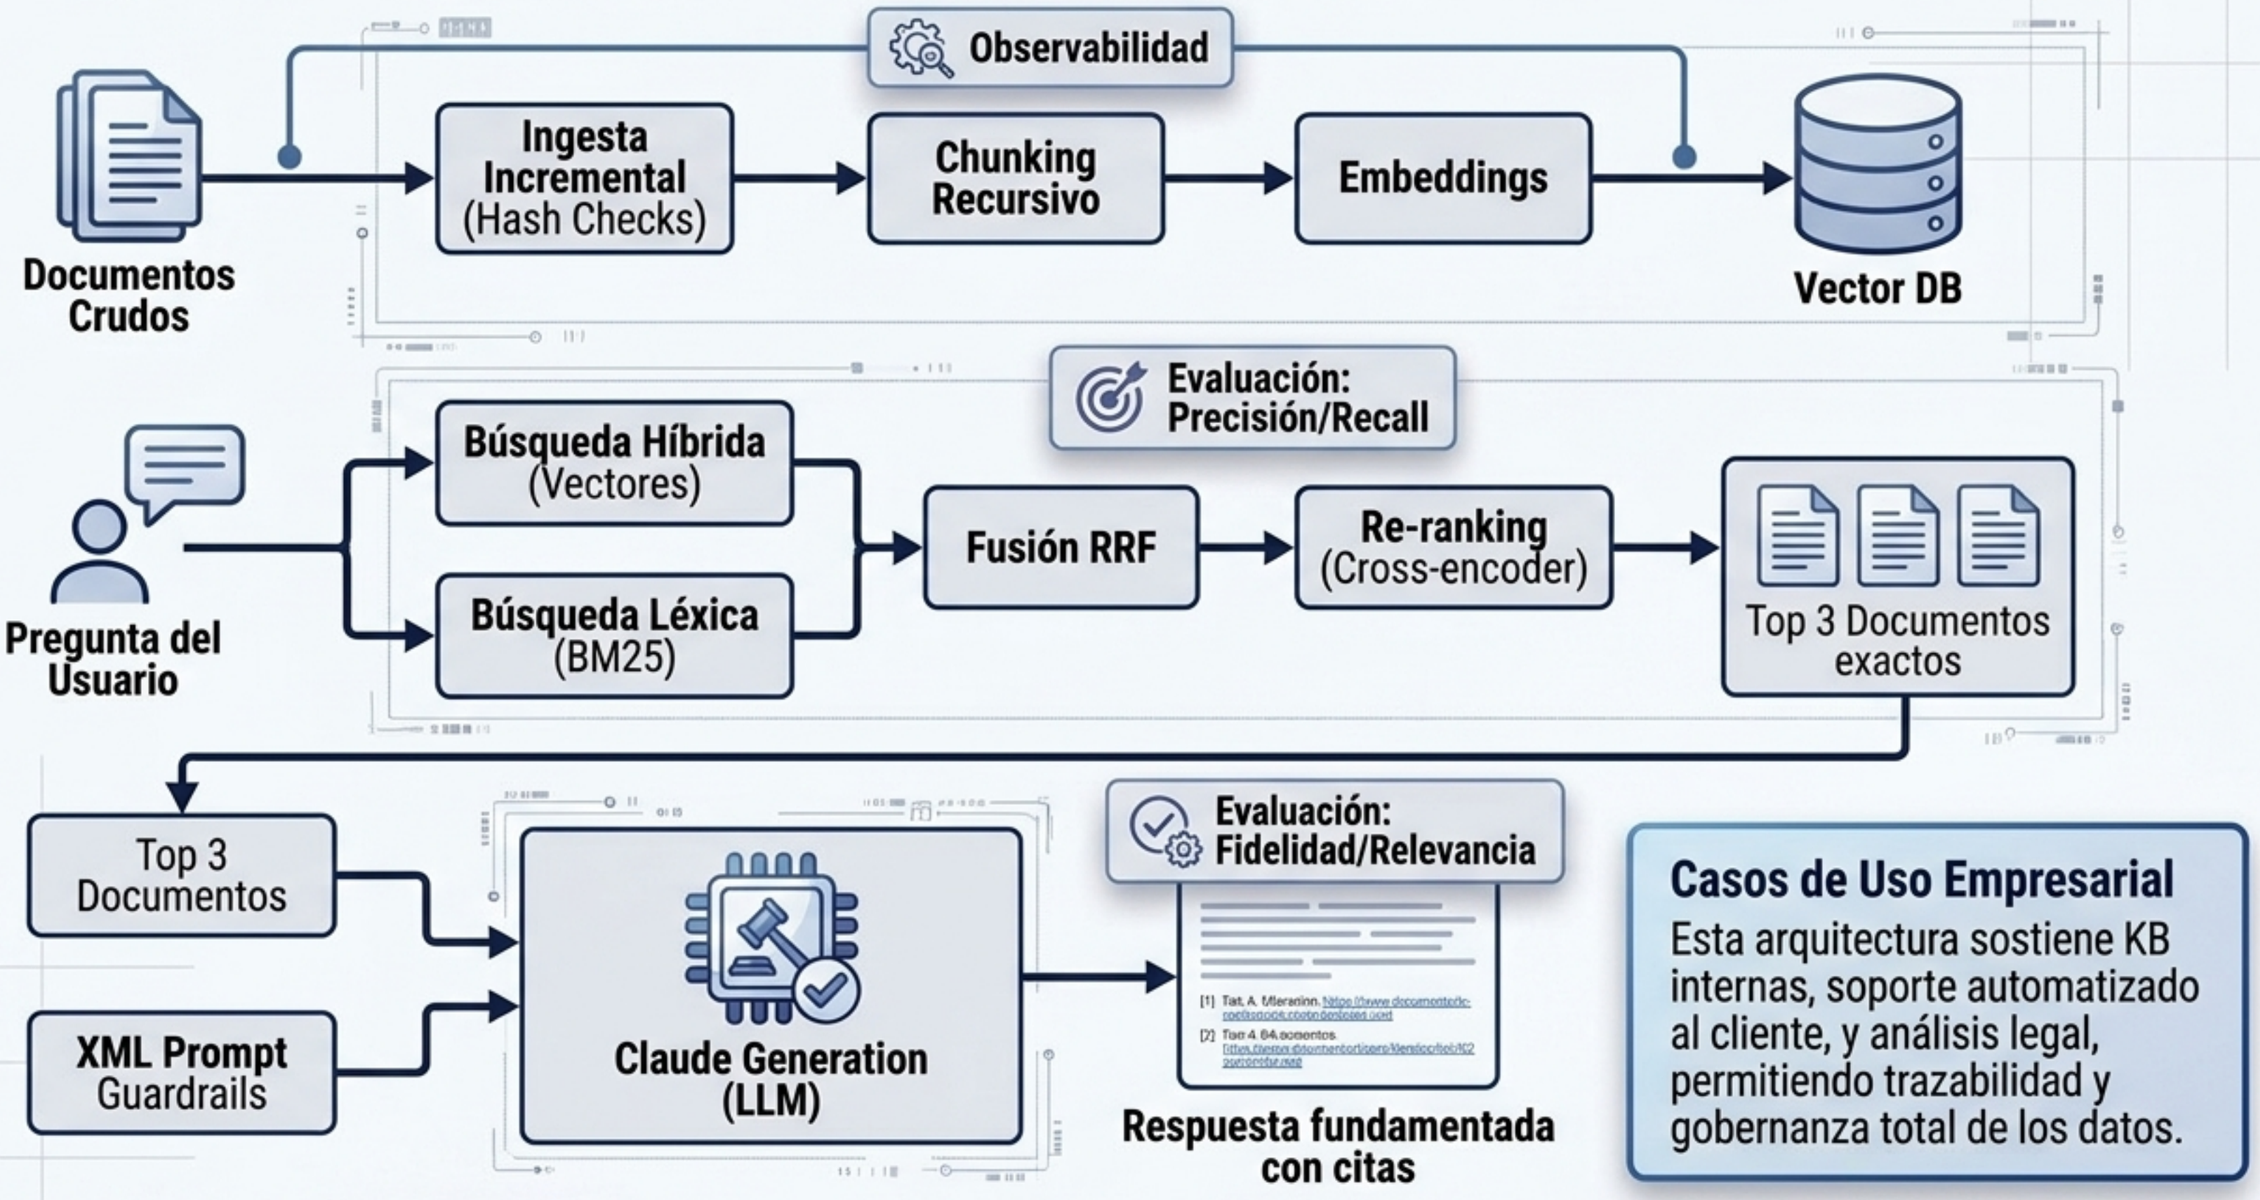
¿Coincide semánticamente con la respuesta humana "de referencia" (Golden Dataset)?

La técnica LLM-as-a-Judge

Frameworks como RAGAS automatizan la evaluación usando modelos avanzados para calificar estos criterios en rúbricas estrictas, haciendo escalable el testing continuo.

Gemini Notebook

La arquitectura maestra: RAG en producción



Casos de Uso Empresarial

Esta arquitectura sostiene KB internas, soporte automatizado al cliente, y análisis legal, permitiendo trazabilidad y gobernanza total de los datos.

Gemini Notebook