SOBERANÍA DE IA

EL PLAYBOOK DE ARQUITECTURA PARA MODELOS LOCALES Y FINE-TUNING

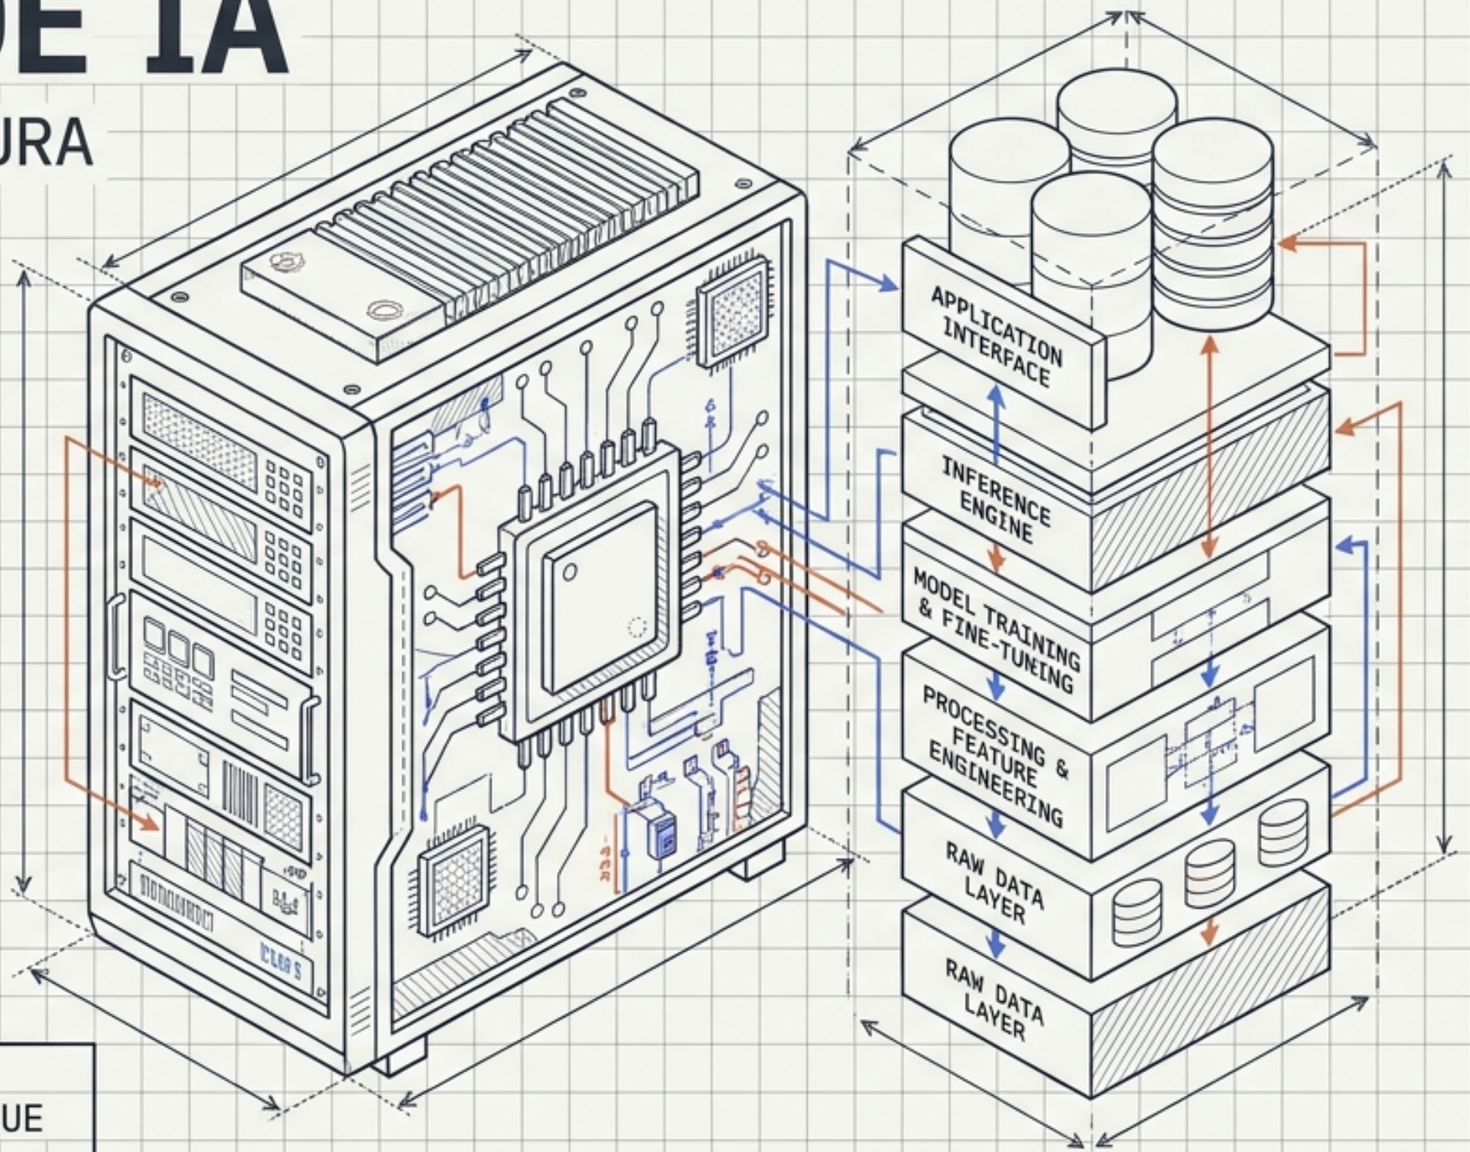

[STATUS]
ENTORNO:
LOCAL

[TARGET]
NIVEL: 10 //
ESTRATEGIA Y DESPLIEGUE

Gemini Notebook

EL IMPERATIVO DE LA IA LOCAL

PRIVACIDAD Y CUMPLIMIENTO (GDPR)

Los datos nunca abandonan la infraestructura. Decisivo para información médica, financiera o código propietario.

CONTROL DE COSTOS (MARGINAL CERO)

Las APIs cobran por token (crecimiento lineal). El modelo local tiene costo fijo (hardware/electricidad). Rentable en volúmenes altos.

CONTROL OPERATIVO (SOBERANÍA)

Control absoluto sobre la versión del modelo (sin cambios silenciosos), disponibilidad offline y parámetros de generación.

CASO DE MISIÓN CRÍTICA

- **Escenario:** Clínica médica procesando historias clínicas.
- **Riesgo:** Enviar datos a una API externa viola políticas de confidencialidad.
- **Solución Local:** Modelo de 8B parámetros en servidor interno. Privacidad total, latencia predecible, costo marginal nulo.

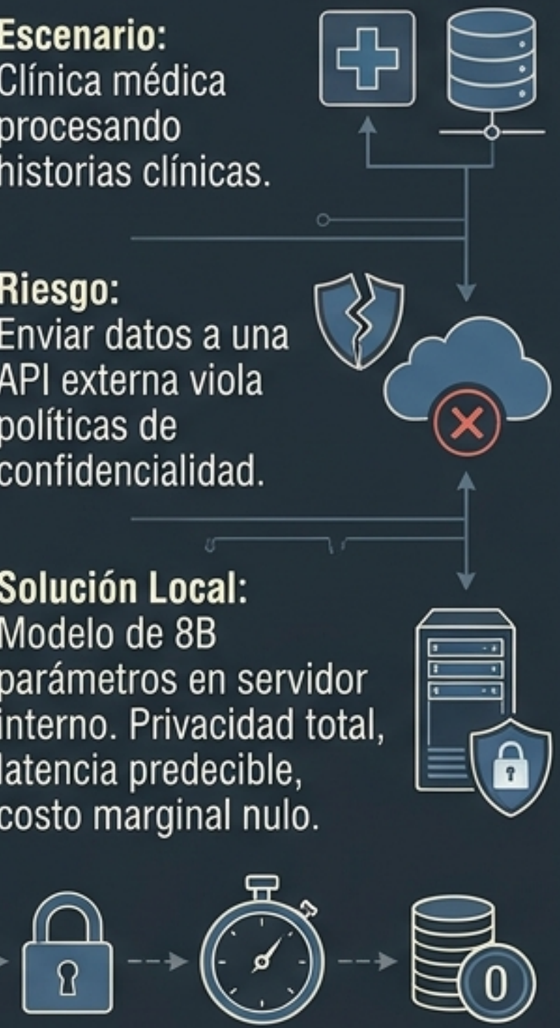

Gemini Notebook

MATRIZ DE DIAGNÓSTICO ARQUITECTÓNICO

Dimensión	Modelo Local	API en la Nube
Privacidad	✔ Total (Datos en casa)	⚠ Depende del contrato
Calidad Máxima	○ Buena (Hasta 70B)	✔ Superior (Modelos de frontera)
Latencia / Red	✔ Predecible / Funciona Offline	⚠ Depende de red y carga
Personalización de Pesos	✔ Total (Acceso a la arquitectura)	○ Limitada
Mantenimiento	○ A cargo del equipo interno	✔ A cargo del proveedor

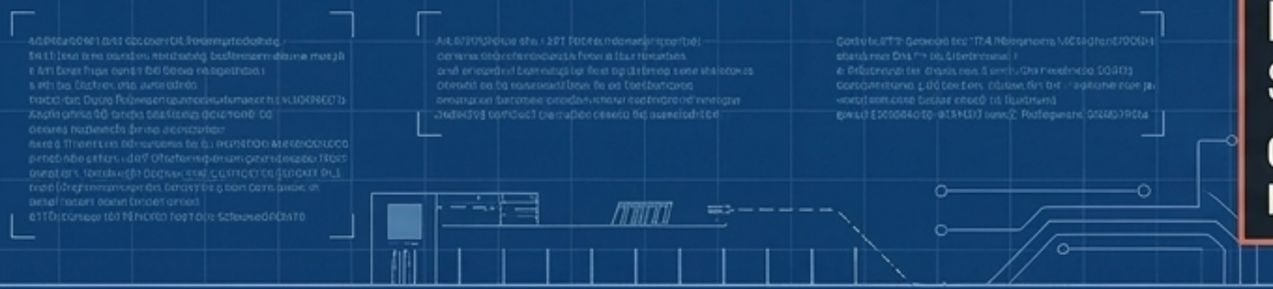

FÓRMULA DE RETORNO DE INVERSIÓN (ROI)

Si **C** > **H** de forma sostenida -> Migrar a Local

C = Costo mensual estimado en API (tokens)
H = Costo mensual de hardware amortizado + energía + mantenimiento

Gemini Notebook

EL ECOSISTEMA DE MODELOS OPEN-WEIGHTS

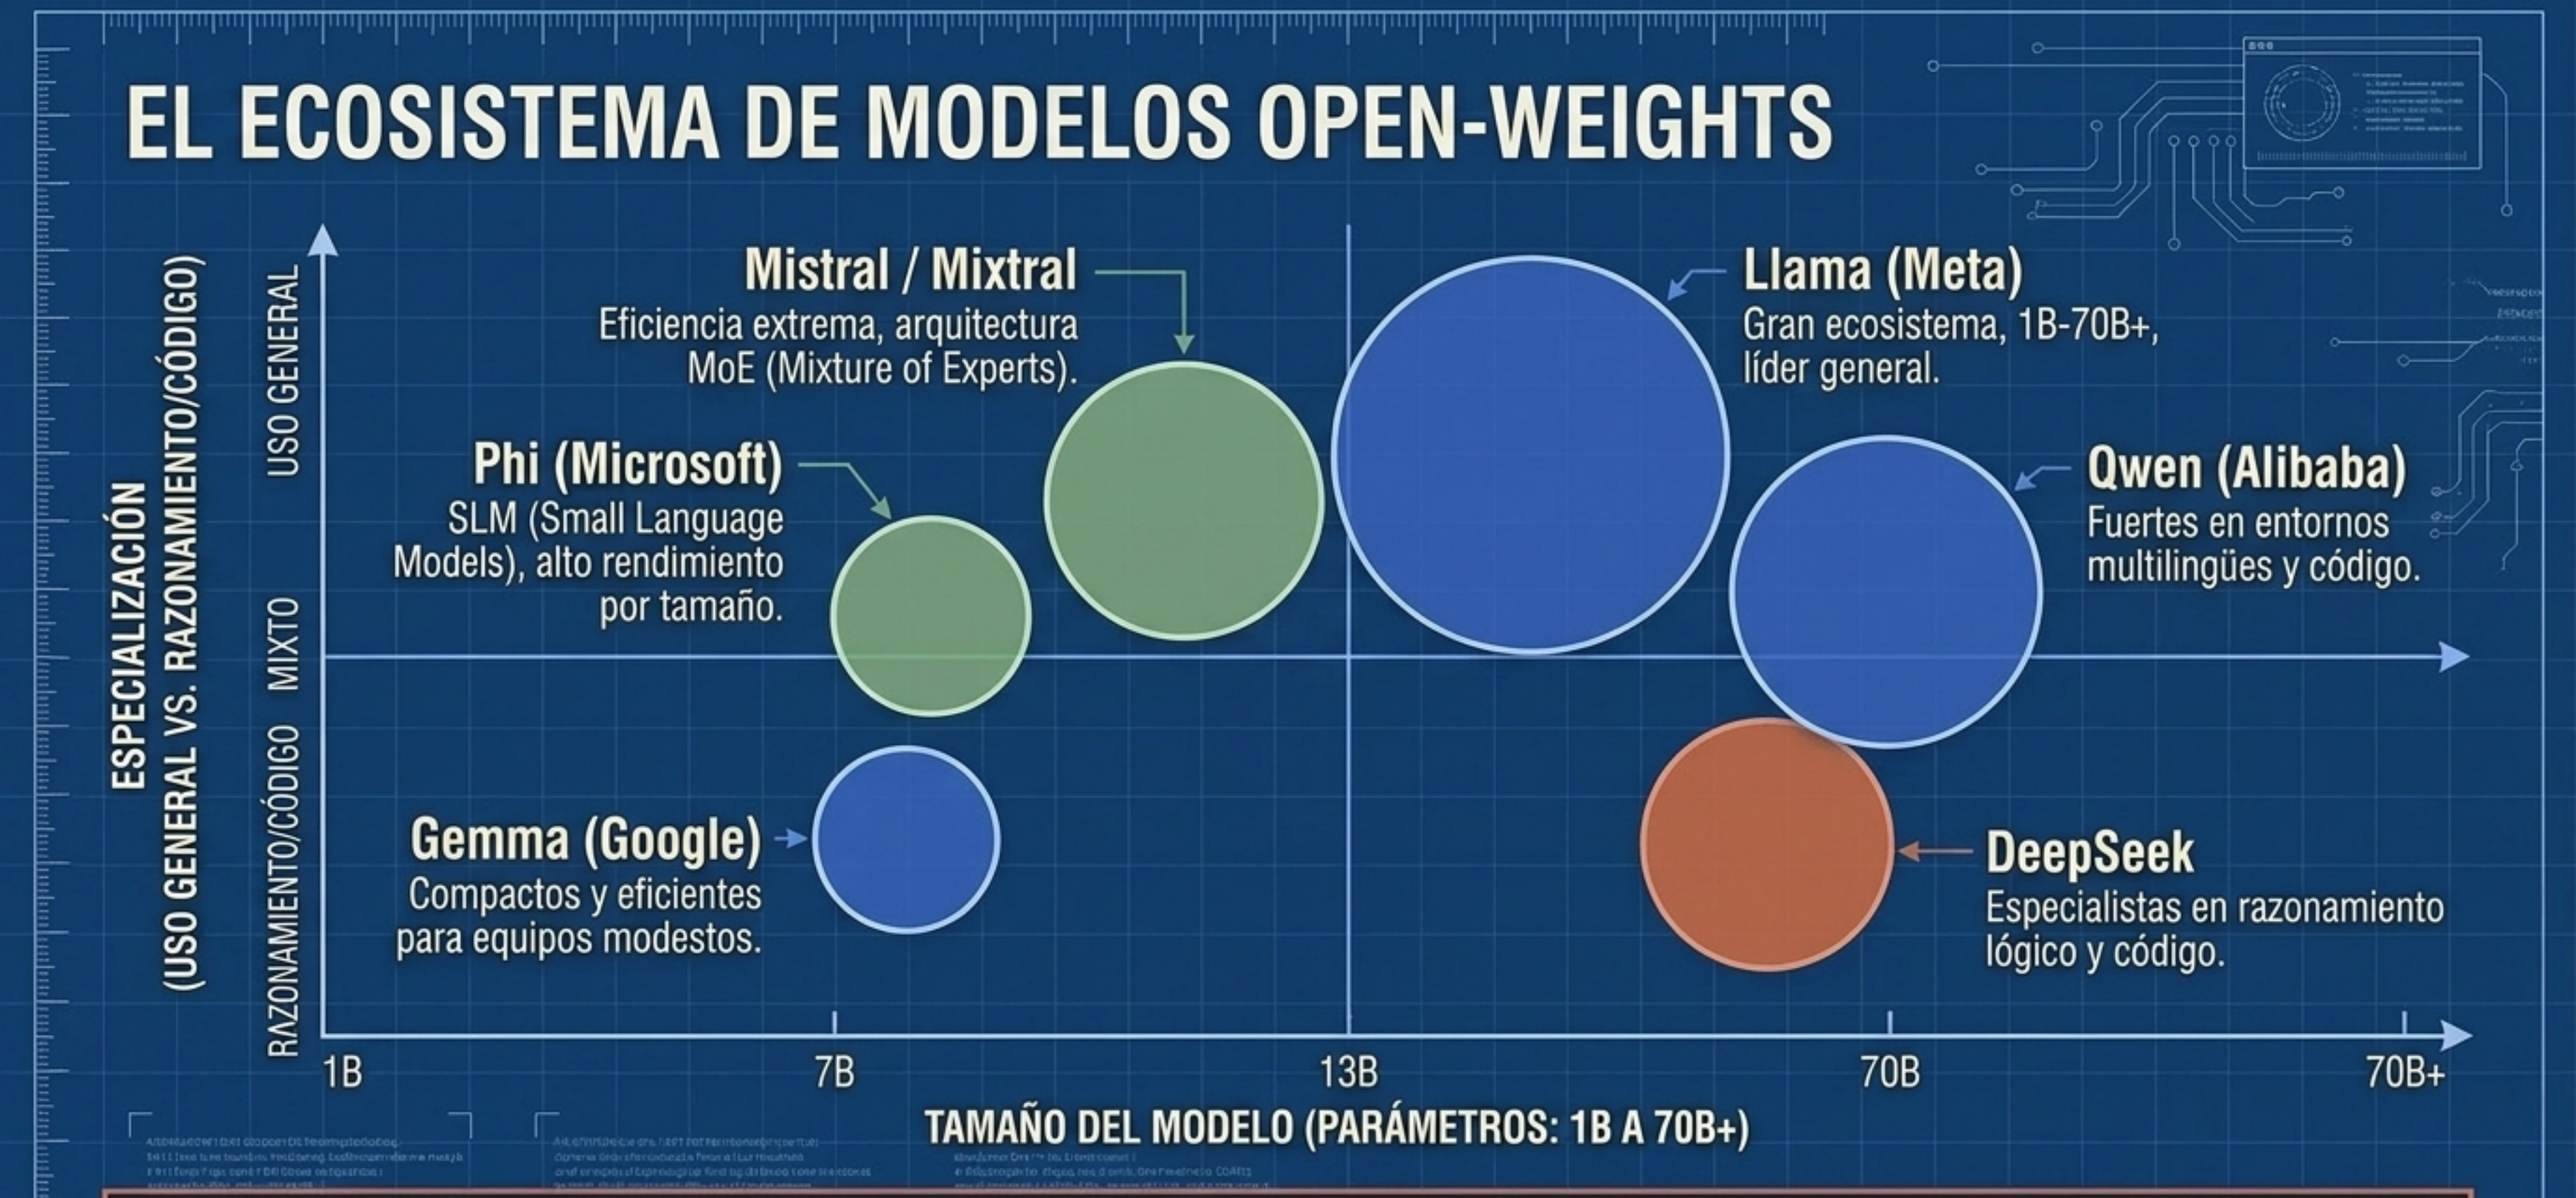

REGLA PRÁCTICA: Comience por el modelo más pequeño que resuelva su tarea con calidad aceptable. Pruebe con casos reales, no con benchmarks genéricos.

Gemini Notebook

MOTORES DE EJECUCIÓN: LA INTERFAZ Y LA CONSOLA

Ollama (La Consola)

Automatización excelente, servicio en segundo plano, despliegue en servidor.

```
> ollama pull llama3.2
> ollama run llama3.2
> ollama ps
```

LM Studio (La Interfaz Visual)

Catálogo visual de Hugging Face, control gráfico de temperatura/VRAM, ideal para escritorio y pruebas rápidas.

INTEGRACIÓN DE API UNIVERSAL

```python
import ollama

# Integración nativa en 4 líneas
respuesta = ollama.chat(
    model='llama3.2',
    messages=[{'role': 'user', 'content': 'Resume los beneficios locales.'}]
)
```

Gemini Notebook

VISUALIZANDO LA CUANTIZACIÓN

La cuantización reduce la precisión numérica de los pesos (de 16 bits a 4 bits) para acelerar inferencia y reducir memoria, con pérdida marginal de calidad.

Modelo FP16 (16-bit)

Modelo 8B = ~16 GB VRAM

Demasiado grande para GPUs estándar

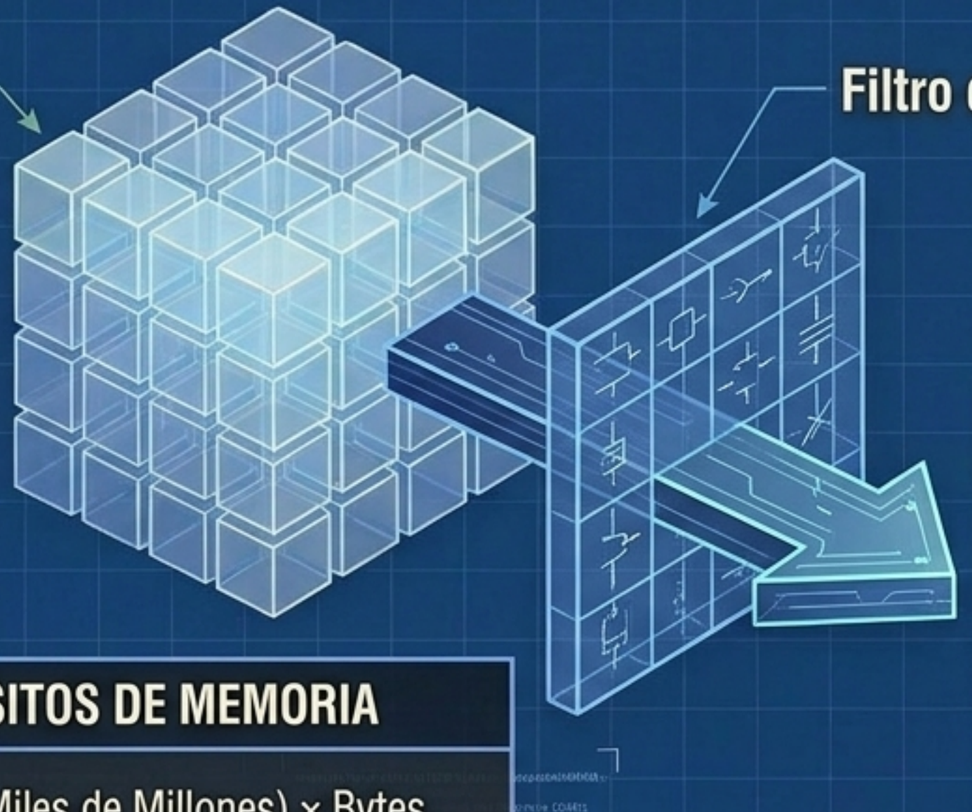

Filtro de Cuantización

Modelo Q4_K_M (4-bit)

Modelo 8B = ~5 GB VRAM

Punto dulce de calidad vs. hardware

FÓRMULA DE REQUISITOS DE MEMORIA

Memoria (GB) = Parámetros (Miles de Millones) × Bytes + 20% (Contexto/KV Cache)

Referencia: FP16 = 2 bytes | 8-bit = 1 byte | 4-bit = 0.5 bytes

Gemini Notebook

Mapeo de Hardware y Capacidades

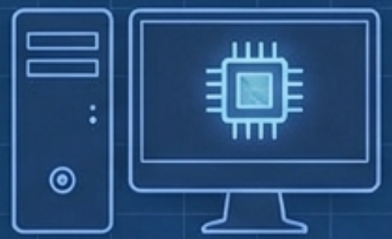

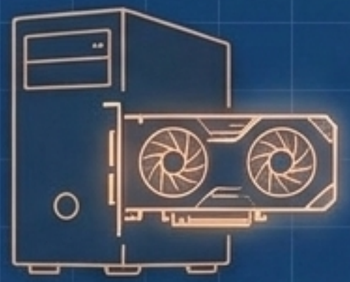

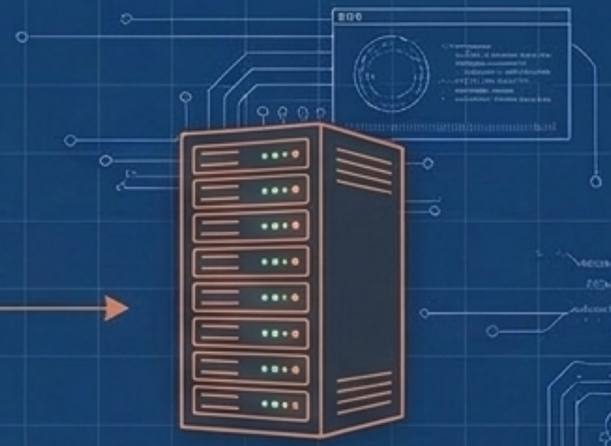

Nivel 1: Laptop

8 GB RAM, Sin GPU

Modelos: 1B a 3B parámetros (Cuantizados).

Uso: Pruebas ligeras, tareas de texto básicas.

Nivel 2: PC Estándar / Mac Silicon Base

16 GB RAM / 8 GB VRAM

Modelos: 7B a 8B parámetros (4-bits, Q4_K_M).

Uso: Asistentes departamentales, código básico, RAG local.

Nivel 3: Workstation GPU

16–24 GB VRAM

Modelos: 13B a 34B parámetros (4-bits).

Uso: Tareas de razonamiento avanzadas, agentes autónomos.

Nivel 4: Servidor Dedicado

48+ GB VRAM

Modelos: 70B+ parámetros (Cuantizados).

Uso: Alternativa total a APIs de frontera, procesamiento masivo corporativo.

Gemini Notebook

La Escalera de la Personalización

REGLA DE ORO: RAG es para el QUÉ (Conocimiento cambiante).
Fine-Tuning es para el CÓMO (Estilo, Tono, Formato y Comportamiento).

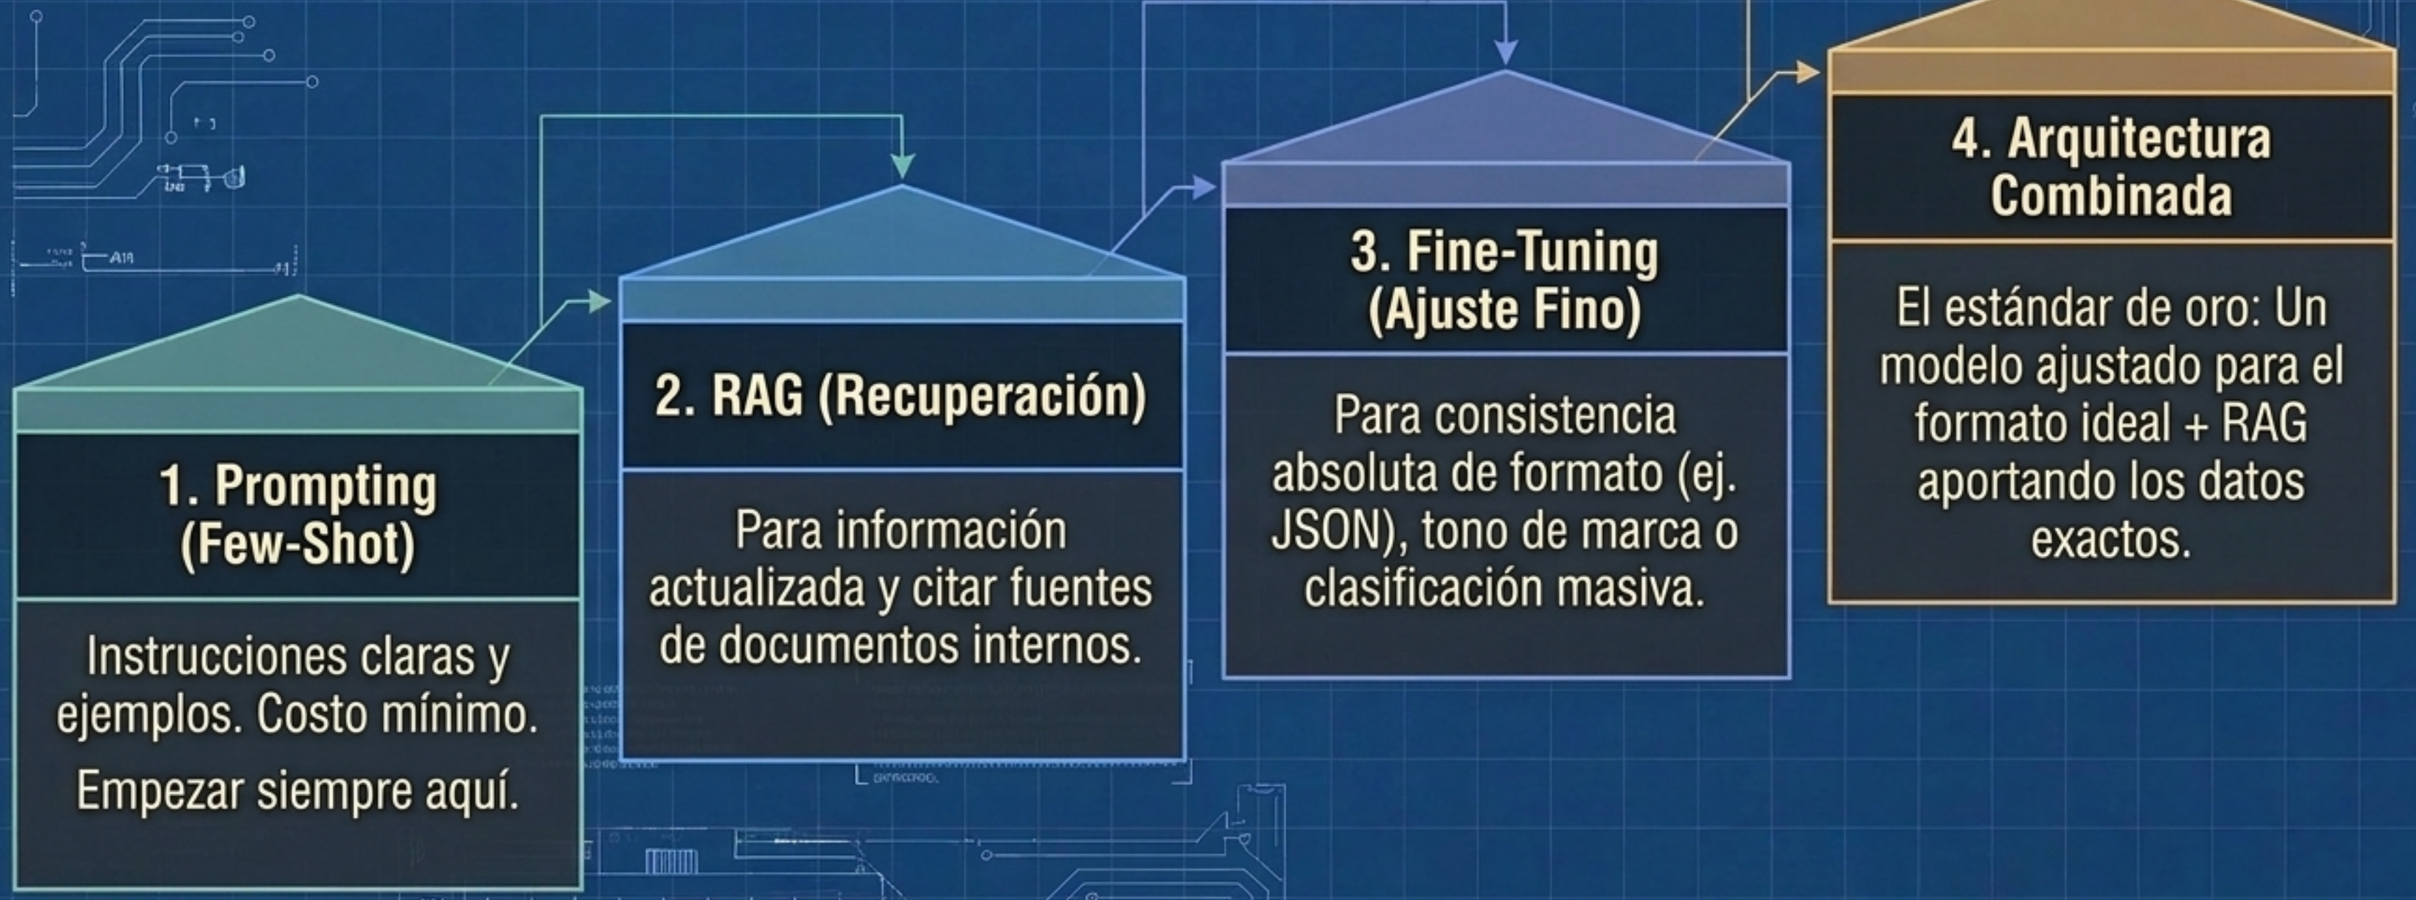

Gemini Notebook

Anatomía de un Dataset de Alta Calidad

ESTRUCTURA JSONL REQUERIDA

```
{ 'messages': [{'role': 'system', 'content': 'Tono cordial...'},
  {'role': 'user', 'content': '¿Cómo reseteo mi clave?'},
  {'role': 'assistant', 'content': 'Ve a Seguridad > Claves...']}
```

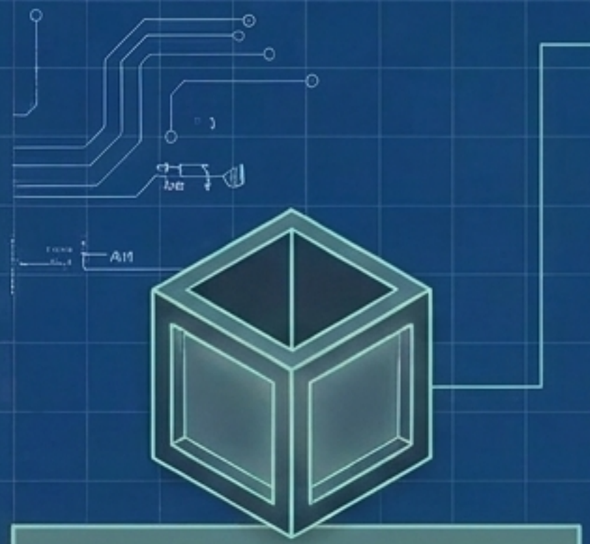

1. Recolección

Tickets, chats, documentos autorizados.

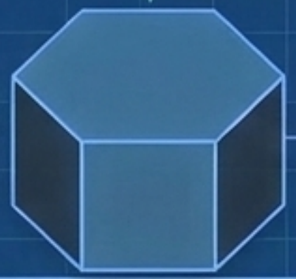

2. Anonimización

Eliminar PII (Nombres, Cuentas, IDs). Crucial para evitar memorización.

3. Curaduría

Calidad > Cantidad.
50 ejemplos perfectos
50 ejemplos perfectos
superan a 1000 mediocres.
Incluir casos difíciles.

4. División

80% Entrenamiento | 10% Validación | 10% Prueba. (El test NUNCA se usa para entrenar).

Gemini Notebook

La Mecánica de LoRA (Low-Rank Adaptation)

El problema del Full Fine-Tuning:
Exige actualizar el 100% de los parámetros (cientos de GB de RAM).

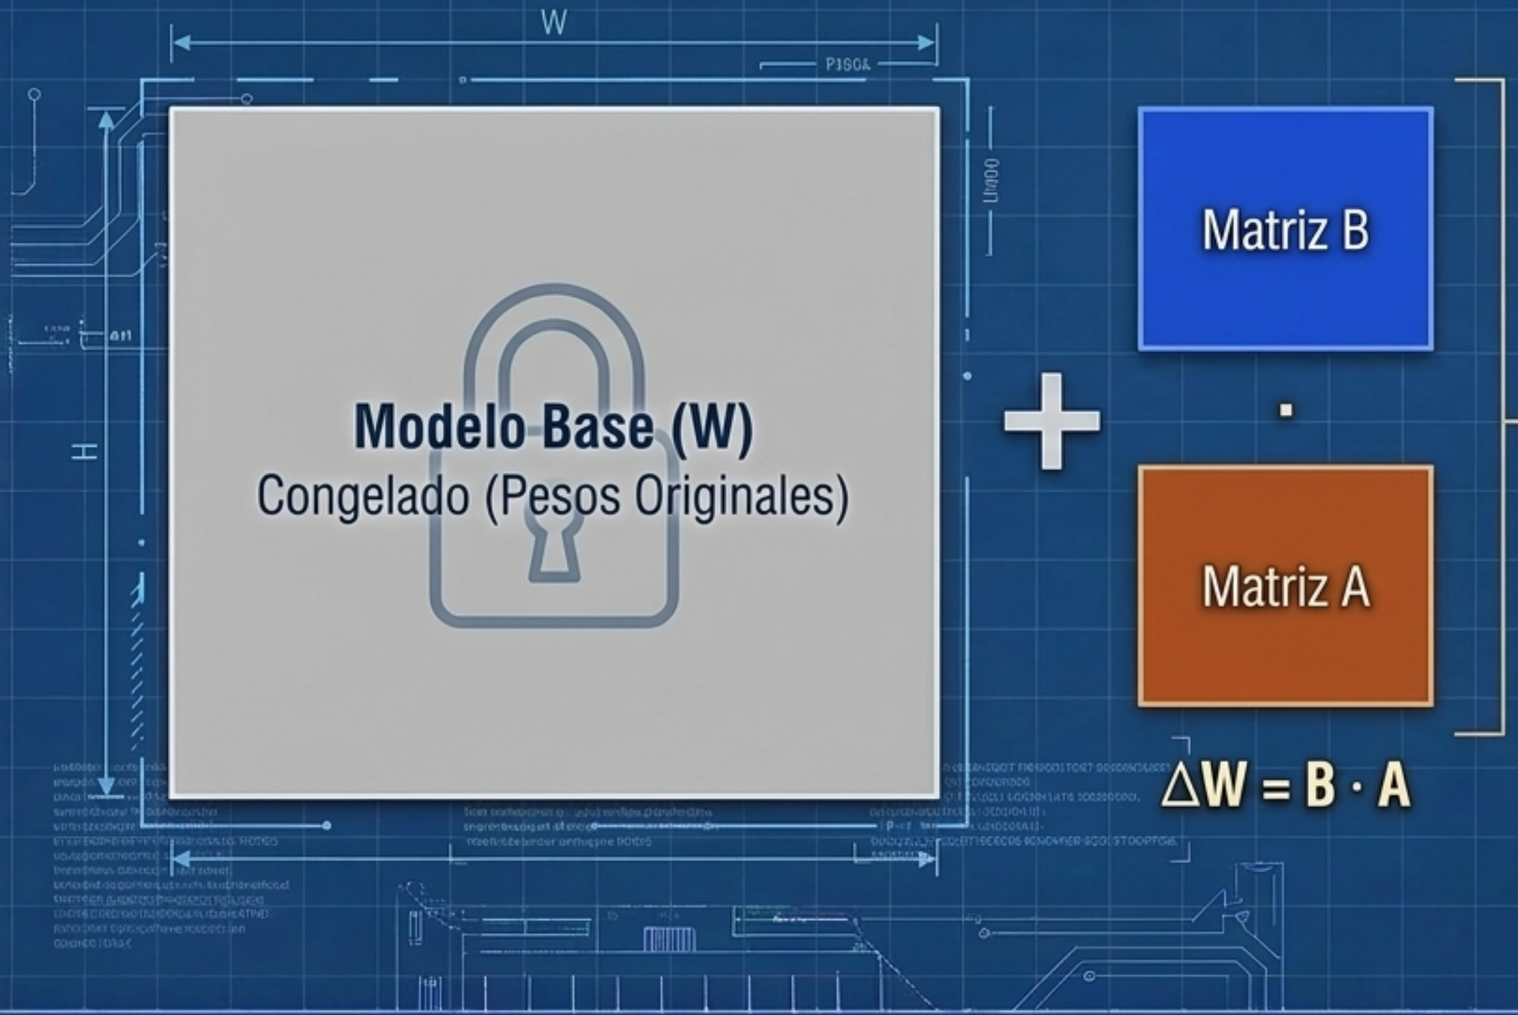

La Solución LoRA

Congelamos el modelo original.
Solo entrenamos dos matrices diminutas (A y B) de rango bajo.
Entrena < 1% de los parámetros totales.

El resultado es un Adaptador ligero de pocos Megabytes que se acopla al modelo gigante original.

QLoRA

Realiza este proceso sobre un modelo base ya cuantizado a 4-bits, permitiendo entrenar en GPUs de consumidor (12-16GB VRAM).

Gemini Notebook

El Flujo de Trabajo Técnico (QLoRA en Hugging Face)

CONFIGURACIÓN DE HIPERPARÁMETROS CLAVE

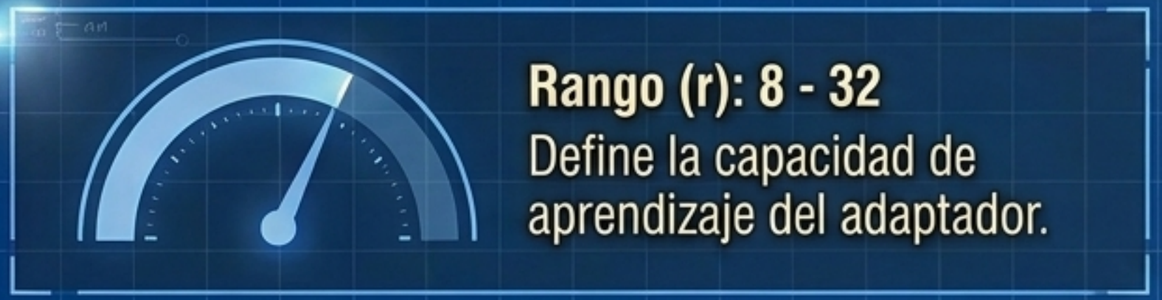

Rango (r): 8 - 32
Define la capacidad de aprendizaje del adaptador.

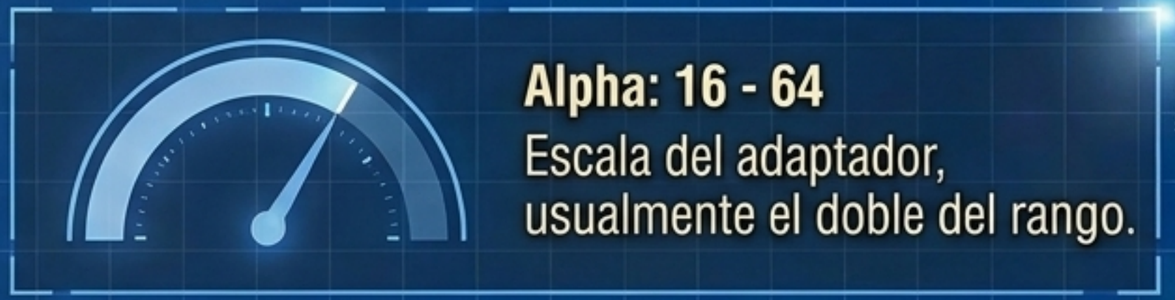

Alpha: 16 - 64
Escala del adaptador, usualmente el doble del rango.

Learning Rate: 1e-4 a 2e-4
Velocidad de aprendizaje del algoritmo.

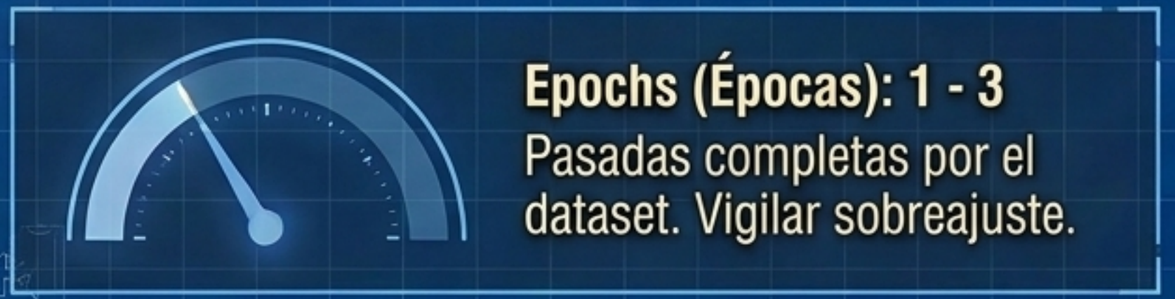

Epochs (Épocas): 1 - 3
Pasadas completas por el dataset. Vigilar sobreajuste.

Gemini Notebook

El Tribunal de Evaluación

1. Métricas Automáticas
Exactitud, F1, validación de formato JSON estructural.

2. LLM como Juez (Rúbrica)
Un modelo de frontera califica consistencia, tono y alucinaciones.

3. Test Ciego Humano
Evaluadores eligen entre el Modelo A y el Modelo B sin saber cuál es el ajustado.

LA REGLA DE LA LÍNEA BASE JUSTA

No compare el modelo ajustado contra el modelo base crudo.
Compárelo contra el modelo base con un excelente Few-Shot Prompting.

Si un buen prompt logra lo mismo, el fine-tuning no se justifica económicamente.

Gemini Notebook

Ética y Puntos Ciegos del Fine-Tuning

Memorización (Privacidad)

Riesgo: El modelo ajustado puede escupir textualmente datos de entrenamiento si se le presiona.

Mitigación: Anonimización extrema de información personal (PII) en el dataset.

Olvido Catastrófico

Riesgo: Mejora en la tarea específica, pero pierde capacidades generales (lógica, matemáticas).

Mitigación: Rango LoRA bajo, pocas épocas, mezclar datos generales en el dataset.

Amplificación de Sesgos

Riesgo: Adoptar malas prácticas, sesgos o lenguaje tóxico presente en los tickets o datos históricos.

Mitigación: Auditoría humana exhaustiva, casos de prueba que cubran diversidad.

Debilitamiento de Seguridad

Riesgo: El fine-tuning puede sobrescribir accidentalmente las barreras de seguridad (guardrails) del modelo base.

Mitigación: Pruebas de estrés rigurosas con casos fuera de alcance o indebidos.

Gemini Notebook

La Arquitectura Híbrida

Solicitud del Usuario

Enrutador Inteligente (Clasifica la intención)

RUTA NUBE: API de Frontera

Condición: Razonamiento complejo, Anónimo/Datos Públicos, Generación Creativa.

Impacto: Capacidad máxima, pago por token solo cuando es estrictamente necesario.

RUTA LOCAL: Servidor On-Premise (Modelo 8B LoRA)

Condición: Datos sensibles (PII), Volumen Masivo, Tareas Repetitivas.

Impacto: Costo marginal cero, Privacidad 100%, Ejecución en milisegundos.

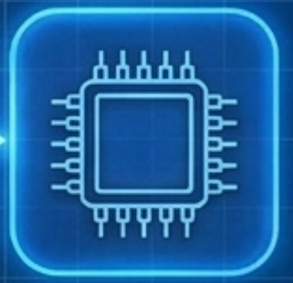

EL ROI DEFINITIVO: Derivar el 80% de la carga trivial o sensible al modelo local, reservando el presupuesto de la nube para el 20% de alta complejidad.

Gemini Notebook

Cheat Sheet de Operaciones Técnicas

CLI DE OLLAMA (OPERACIONES)

> ollama pull <modelo>
Descargar el modelo

> ollama run <modelo>
Iniciar chat en terminal

> ollama show <modelo>
Inspeccionar parámetros y contexto

> ollama ps
Ver uso de VRAM en vivo

EL MODELFILE (PERSONALIZACIÓN)

```
FROM llama3.2

PARAMETER temperature 0.3

PARAMETER num_ctx 4096

SYSTEM 'Eres un asistente
de soporte...'
```

> ollama create asistente -f Modelfile

SETUP BASE LORA (PEFT)

```
r = 16

lora_alpha = 32

dropout = 0.05

target_modules = 'all-linear'

learning_rate = 2e-4

epochs = 2
```

[EXIT 0] Arquitectura desplegada. Sistema listo.

Gemini Notebook